Laboratorio 4.
Árboles de Decisión

INTRODUCCIÓN:

La empresa **SmartStay Advisors** es una firma intermediaria que facilita la búsqueda y selección de propiedades en Airbnb para clientes corporativos y particulares.

El modelo operativo es el siguiente:

- El cliente proporciona requerimientos específicos (ciudad, presupuesto, tipo de propiedad, capacidad, duración de estancia).
- SmartStay analiza la oferta disponible y propone propiedades que optimicen precio, calidad y disponibilidad.
- Airbnb ofrece incentivos económicos a SmartStay cuando logra incrementar el nivel de ocupación de propiedades con bajo desempeño.

La empresa desea implementar modelos de minería de datos que le permitan:

1. Estimar precios competitivos.
2. Identificar propiedades con baja ocupación.
3. Comprender qué factores influyen en la ocupación y los ingresos.
4. Diseñar estrategias basadas en datos para aumentar la rentabilidad.

Conjunto de datos a utilizar

- listings.Rdata (consultar el diccionario de columnas adjunto)
    - **<u>Observación</u>**: pyreadr es un módulo que le permitirá cargar los datos a través de python.

Descripción de la Consultoría:

Esta semana deberá entregar resultados de la aplicación de un algoritmo de predicción y/o clasificación. La conclusión será la elección del mejor algoritmo predictivo para estimar el valor de una vivienda.

Se le provee un diccionario de variables con el nombre y la descripción de cada una de las variables. Le han pedido que cree una variable que agrupe los precios de las casas o apartamentos en 3 categorías: Económicas, Intermedias o Caras, esto teniendo siempre en cuenta, el rango de precio por noche.

Resultados esperados en esta entrega de Consultoría:

Se espera la entrega de un informe detallado donde incluya:

- La descripción de la nueva variable categórica, explicando los límites seleccionados para cada categoría y la justificación de la elección de los valores mínimo y máximo para cada una de las categorías.

- Los modelos de árboles de decisión tanto para predicción del precio de las casas/apartamentos por noche, como de clasificación usando la variable creada.
- Una comparación para estimar los precios de las viviendas donde determine qué algoritmo funcionó mejor (Regresión Lineal, Árboles de regresión, Random Forest). Compare los resultados del mejor modelo de cada uno de los algoritmos.

Notas:

- La consultoría es en grupo, por lo que solo se tendrán en cuenta los grupos conformados por más de un especialista.
- Cada individuo será evaluado de forma individual basado en sus aportes al trabajo grupal, por lo que deben versionar el código para poder revisar las contribuciones de cada uno.

INSTRUCCIONES

Utilice el conjunto de datos que se le provee. Debe hacer un análisis exploratorio para entender mejor los datos, sabiendo que el objetivo final es predecir los precios de las casas. Recuerde explicar bien cada uno de los hallazgos que haga. Siéntase en la liberatd de complementar su análisis exploratorio con cualquier pregunta de investigación que sea relevante para su variable respuesta. Si considera que le falta algo por explorar y cree que lo necesita, hágalo con el objetivo de robustecer su entendimiento del problema.

Genere un informe con las explicaciones de los pasos que llevó a cabo y los resultados obtenidos. Recuerde que la investigación debe ser reproducible por lo que debe guardar el código que ha utilizado para resolver los ejercicios.

ACTIVIDADES

1. Descargue el conjunto de datos.
2. Haga un análisis exploratorio extenso de los datos. Explique bien todos los hallazgos. No ponga solo gráficas y código. Debe llegar a conclusiones interesantes para poder predecir. Explique el preprocesamiento que necesitó hacer.
3. Incluya un análisis de grupos en el análisis exploratorio. Explique las características de cada uno.
4. Divida el set de datos preprocesados en dos conjuntos: Entrenamiento y prueba. Describa el criterio que usó para crear los conjuntos: número de filas de cada uno, estratificado o no, balanceado o no, etc.
5. Elabore un **árbol de regresión** para predecir el <u>precio de las casas</u> por noche usando **todas las variables**.
6. Úselo para predecir y analice el resultado. ¿Qué tal lo hizo?
7. Haga, al menos, 3 modelos más, cambiando el parámetro de la profundidad del árbol y/o la selección de variables que hayan considerado. ¿Cuál es el mejor modelo para predecir el precio por noche?
8. Ahora, compare **los resultados con un modelo de regresión lineal**. Para esto, con el análisis exploratorio y el entendimiento de los datos, deberá elaborar como un primer paso un

modelo de regresión lineal. Trate de iterar varias veces de tal manera que pueda llegar al **mejor modelo posible** (a través de una selección de variables fundamentada, aplicando o no regularización en caso lo vea conveniente, etc.) y tome ese modelo y **compárelo con el mejor modelo de árboles de regresión** obteniodo en el inciso anterior. ¿Cuál lo hizo mejor? Recuerde que su variable respuesta sigue siendo el precio de las casas.

9. Dependiendo del análisis exploratorio elaborado cree una variable respuesta que le permita clasificar las casas en Económicas, Intermedias o Caras. Los límites de estas clases deben tener un fundamento en la distribución de los datos de precios, y estar bien explicados.
10. Elabore un árbol de clasificación utilizando la variable respuesta que creó en el punto anterior. Explique los resultados a los que llega. Muestre el modelo gráficamente. Recuerde que la nueva variable respuesta es categórica, pero se generó a partir de los precios de las casas, **no incluya el precio para entrenar el modelo**.
11. Utilice el modelo con el conjunto de prueba y determine la eficiencia del algoritmo para clasificar.
12. Haga un análisis de la eficiencia del algoritmo usando una matriz de confusión para el árbol de clasificación. Tenga en cuenta la efectividad, donde el algoritmo se equivocó más, donde se equivocó menos y la importancia que tienen los errores.
13. Entrene un modelo usando validación cruzada, prediga con él. ¿le fue mejor que al modelo anterior?
14. Haga al menos, 3 modelos más, cambiando la profundidad del árbol. ¿Cuál funcionó mejor?
15. Repita los análisis usando random forest como algoritmo de predicción, explique sus resultados comparando ambos algoritmos.

EVALUACIÓN

Nota: Tiene que poderse comprobar su aporte al trabajo grupal a través de commits. Si no existen al menos 3 commits con su aporte significativo no va a tener nota de la hoja de trabajo. Utilice una herramienta que permita registrar los aportes de cada uno.

- **(10 puntos)** Creación de la variable respuesta para árbol de clasificación. Explicación de los límites de las categorías.
- **(8 puntos)** Generación del modelo de regresión. Análisis de los resultados obtenidos
- **(8 puntos)** Comparación del árbol de regresión con el modelo de regresión lineal de la hoja anterior. Explicación de resultados
- **(8 puntos)** Tuneo del parámetro de la profundidad del árbol. Selección del mejor modelo, todo está explicado claramente.
- **(12 puntos)** Árbol de Clasificación. Representación gráfica del modelo.
- **(12 puntos)** Modelo con validación Cruzada y tuneo de la profundidad del árbol de clasificación.
- **(12 puntos)** Random Forest
- **(30 puntos)** Análisis de resultados de aplicación del algoritmo para predecir o clasificar sobre el conjunto de prueba. Comparación entre algoritmos.

MATERIAL A ENTREGAR

- Archivo .rmd, .ipynb o Google docs con el informe con lo solicitado en las instrucciones
- Script de R o de Python que utilizó debidamente organizado y comentado (Si utilizó rmd debe añadir el html que se genera)
- Link de controlador de versiones utilizado.

FECHAS DE ENTREGA

- **PASAPORTE:** Puntos del 1 al 10 de la sección de actividades: viernes 20 de marzo a las 17:20.
- **ENTREGA FINAL:** domingo 22 de marzo a las 23:59

NOTA:

- No se aceptará ningún resultado sin explicaciones de los hallazgos y/o análisis.
- Para poder tener nota completa debe entregar las asignaciones en el tiempo adecuado. No se calificará el avance (pasaporte) de la entrega si no fue subido en tiempo, aunque esté en el repositorio.
- Si alguno de los miembros del grupo de trabajo no llega al trabajo colaborativo en clase, no tendrá derecho a la nota del laboratorio.
- La descripción y explicación de resultados es crucial en el análisis de los datos por lo que no se tomarán en cuenta gráficos o tablas que no estén explicadas ni para avances ni para entrega final.
- Se tomarán en cuenta las contribuciones individuales para calificar el trabajo de cada uno, si no tiene suficientes contribuciones significativas en código y en análisis no tiene derecho a nota.